Лабораторна робота

Статистичний аналіз даних на мові R

R – це мова програмування, яка широко використовується для аналізу даних. В цій роботі ми будемо використовувати бібліотеки

• dplyr: для очищення та трансформації даних

• ggplot2: для візуалізації даних

Ці бібліотеки завантажуються з допомогою команди install.packages. Створіть новий файл (File -> New File -> RScript) та скопіюйте наступні рядки:

```
install.packages("dplyr")
install.packages("ggplot2")
```

Щоб виконати код, виділіть рядки та натисніть піктограму Run з зеленою стрілкою або комбінацію клавіш CTRL + ENTER або COMMAND + ENTER.

Далі завантажте ці бібліотеки до вашого робочого середовища. Це можна зробити за допомогою функції **library()**. Зауважте, що ми встановлюємо бібліотеку один раз, але завантажувати її потрібно щоразу, як ви перезапускаєте RStudio. Тобто при наступному запуску RStudio команди інсталяції не будуть потрібні і їх можна буде закоментувати використовуючи символ #:

```
#install.packages("dplyr")
#install.packages("ggplot2")
```

Додайте рядки:

```
library(dplyr)
library(ggplot2)
```

Імпорт даних

Помістіть файл "flats.csv" у ту ж папку, де знаходиться створений вами RScript. Завантажте дані з файла "flats.csv" у змінну `flats` використовуючи функцію read.csv.

```
flats <- read.csv("flats.csv", stringsAsFactors=FALSE,
encoding="UTF-8")
```

Параметр `encoding="UTF-8"` використовується для коректного відображення кирилиці у OS Windows.

Параметр `stringsAsFactors=FALSE` вказує, що змінні, які мають тип character не будуть перетворюватись у тип даних factor. Цей тип використовується для роботи з категоріальними змінними, однак в межах цієї лабораторної ми не будемо його використовувати.

Якщо отримали помилку

```
Error in file(file, "rt") : cannot open the connection In
addition: Warning message: In file(file, "rt") : cannot open file
'flats.csv': No such file or directory
```

вкажіть шлях до цієї директорії використовуючи команду **setwd** (скорочення від set working directory). Виконання цієї команди дозволяє не вказувати повний шлях до цієї директорії.

```
setwd("шлях до файла")
# приклад:
#setwd("~/work/stats_course/materials/week2")
```

Визначимо клас об'єкта `flats` за допомогою команди **`class()`**

```
class(flats)
```

```
[1] "data.frame"
```

Клас об'єкта `flats` – data.frame або таблиця даних. Кожен рядок цієї таблиці представляє спостереження, а кожна колонка відображає змінну, тобто частину інформації про це спостереження. В R ви можете використовувавит функцію **str()** (скорочення від structure) щоб швидко оцінити, чи правильно зчиталися ваші дані.

```
str(flats)
```

```
'data.frame': 839 obs. of  4 variables:
 $ Місто          : chr  "Вінниця" "Вінниця" "Вінниця" "Вінниця" ...
 $ Кімнат         : int  3 3 2 2 3 1 3 3 1 6 ...
 $ Загальна_площа: chr  "120" "66" "66" "44" ...
 $ Ціна           : num  1875000 975000 1375000 637500 835000 ...
```

Бачимо, що змінна Загальна_площа має тип "character", тобто розпізналася як текстова змінна. Переглянемо документацію по функції read.csv використовуючи функцію **?**

```
?read.csv
```

Бачимо, що в якості десяткового розділювача по замовчуванню використовується крапка dec ='.'. А в наших даних десятковим розділювачем є кома.

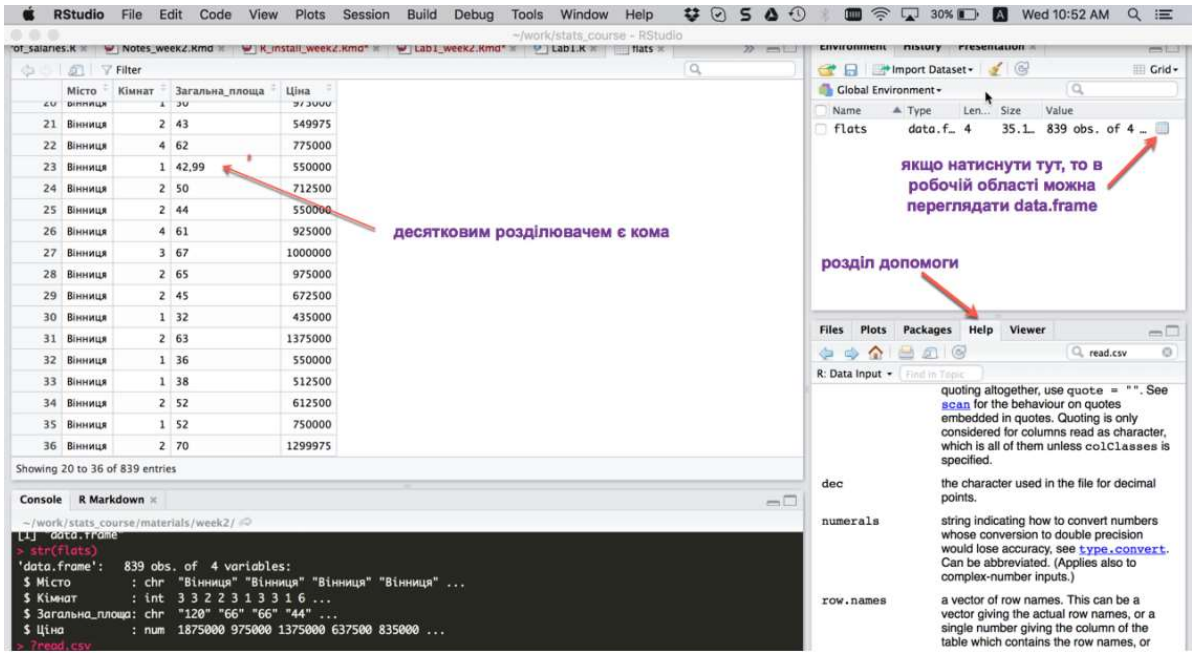

Заново зчитаємо дані, вказавши параметр десяткового розділювача:

```
flats <- read.csv("flats.csv", stringsAsFactors=FALSE, dec= ",",
encoding="UTF-8")
```

Перевіримо їх структуру:

```
str(flats)
```

```
'data.frame': 839 obs. of  4 variables:
 $ Місто         : chr  "Вінниця" "Вінниця" "Вінниця" "Вінниця" ...
 $ Кімнат        : int  3 3 2 2 3 1 3 3 1 6 ...
 $ Загальна_площа: num  120 66 66 44 63 31 46 64 35 200 ...
 $ Ціна          : num  1875000 975000 1375000 637500 835000 ...
```

Аналіз даних

• Для того, щоб знайти розмірність, використовується функція **dim()**;

• **head()** відображає першу частину об'єкта, першим параметром є об'єкт (тут таблиця даних flats, другим параметром можна вказати кількість рядків);

• **tail()** відображає останню частину об'єкта, теж можна вказати кількість рядків;

• **names()** – імена, пов'язані з об'єктом.

ВПРАВИ (1-3)

• Знайдіть розмірність датафрейму flats.

• Відобразіть перші шість рядків, перші п'ятнадцять рядків, останні шість рядків.

• Відобразіть імена датафрейму.

Трансформація даних

В R ви можете використовувати функцію **str()** та **summary()** щоб отримати початкову інформацію про таблицю. Бібліотека **dplyr** має функцію **glimpse()** для швидкого узагальнення таблиці.

```
# Look at structure of flats
```

```
str(flats)
```

```
'data.frame': 839 obs. of  4 variables:
 $ Місто         : chr  "Вінниця" "Вінниця" "Вінниця" "Вінниця" ...
 $ Кімнат        : int  3 3 2 2 3 1 3 3 1 6 ...
 $ Загальна_площа: num  120 66 66 44 63 31 46 64 35 200 ...
 $ Ціна          : num  1875000 975000 1375000 637500 835000 ...
```

```
# View a summary of flats
summary(flats)
```

```
    Місто               Кімнат      Загальна_площа        Ціна          
 Length:839         Min.   :1.000   Min.   : 14.00   Min.   :   10200  
 Class :character   1st Qu.:1.000   1st Qu.: 43.75   1st Qu.:  537500  
 Mode  :character   Median :2.000   Median : 56.00   Median :  775000  
                    Mean   :2.045   Mean   : 64.07   Mean   : 1042710  
                    3rd Qu.:3.000   3rd Qu.: 75.00   3rd Qu.: 1200000  
                    Max.   :6.000   Max.   :222.60   Max.   :12250000  
```

```
# Get a glimpse of flats
glimpse(flats)
```

```
Observations: 839
Variables: 4
$ Місто          <chr> "Вінниця", "Вінниця", "Вінниця", "Вінниця",
"Вінниця", "Вінниця", "Вінниця", "Вінниця", "Вінниця", "Вінниця...
$ Кімнат         <int> 3, 3, 2, 2, 3, 1, 3, 3, 1, 6, 2, 1, 1, 2, 3, 3,
3, 2, 1, 1, 2, 4, 1, 2, 2, 4, 3, 2, 2, 1, 2, 1, 1, 2, 1, 2,...
$ Загальна_площа <dbl> 120.00, 66.00, 66.00, 44.00, 63.00, 31.00, 46.00,
64.00, 35.00, 200.00, 46.00, 50.00, 38.00, 68.00, 98.00, ...
$ Ціна           <dbl> 1875000, 975000, 1375000, 637500, 835000, 562500,
1150000, 800000, 424975, 12500, 500000, 999975, 512500, 1...
```

Дізнаємося, яка кількість квартир продається у кожному місті (згідно цього набору даних):

В бібліотеці **dplyr** для цього є функція **count**:

```
count(flats, Місто)
```

```
# A tibble: 13 × 2
                Місто     n
                <chr> <int>
1              Вінниця   275
2      Дніпропетровськ    18
3            Запоріжжя    13
4     Івано-Франківськ    47
5  Києво-Святошинський    19
6                Київ   186
7               Львів    16
8            Миколаїв    15
9               Одеса    43
10              Рівне    23
11           Тернопіль    93
12             Харків    14
13        Хмельницький    77
```

Якщо ми хочемо виконати послідовно кілька операцій в **dplyr** можна використати оператор **%>%**, який дозволяє застосувати наступну команду до результатів виконання поточної. Наприклад, посортуємо дані по кількості квартир у кожному місті у зростаючому порядку:

```
flats %>%
  count(Місто) %>%
  arrange(n)
```

```
# A tibble: 13 × 2
                Місто     n
                <chr> <int>
1            Запоріжжя    13
2              Харків    14
3            Миколаїв    15
4               Львів    16
5      Дніпропетровськ    18
6  Києво-Святошинський    19
7               Рівне    23
8               Одеса    43
9     Івано-Франківськ    47
10        Хмельницький    77
11           Тернопіль    93
12               Київ   186
13             Вінниця   275
```

Як бачимо, Києво-Святошинський район виділений в окреме місто. Можливо тому, що його адміністративним центром є місто Київ. Вилучимо ці дані з відображення використовуючи команду **filter**. Нагадаємо, що умова дорівнює позначається як ==, а не дорівнює як !=. Також посортуємо результати в спадаючому порядку для цього вкажемо **arrange(desc(n))**.

```
flats %>%
  filter(Місто != "Києво-Святошинський") %>%
  filter(Кімнат == 3) %>%
  count(Місто) %>%
  arrange(desc(n)) # arrange - сортування, desc - спадаючий
порядок
```

```
# A tibble: 12 × 2
             Місто     n
             <chr> <int>
1           Вінниця    60
2              Київ    50
3         Тернопіль    24
4      Хмельницький    22
5  Івано-Франківськ    13
6             Одеса    11
7   Дніпропетровськ     8
8         Запоріжжя     8
9             Рівне     6
10         Миколаїв     5
11           Харків     3
12            Львів     2
```

Якщо нас цікавлять кількість двокімнатних квартир в кожному місті, то виберемо лише квартири з кількістю кімнат 2:

```
flats %>%
  filter(Кімнат == 2) %>%
  filter(Місто != "Києво-Святошинський") %>%
  count(Місто) %>%
  arrange(desc(n))
```

```
# A tibble: 12 × 2
              Місто     n
              <chr> <int>
1           Вінниця    93
2              Київ    67
3         Тернопіль    43
4      Хмельницький    28
5             Одеса    18
6  Івано-Франківськ    14
7             Рівне     8
8          Миколаїв     7
9            Харків     7
10  Дніпропетровськ     5
11            Львів     5
12        Запоріжжя     2
```

Функція **summarise** дозволяє узагальнити дані. Наприклад, знайти середнє значення площі квартир в кожному регіоні. Для обрахунку середнього значення використаємо функцію **mean**.

```
flats %>%
  filter(Кімнат == 2) %>%
  filter(Місто != "Києво-Святошинський") %>%
  summarise(mean(Загальна_площа))
```

```
  mean(Загальна_площа)
1             60.81832
```

Можна обчислити не лише площу, але й середньоквадратичне відхилення за допомогою функції **sd**:

```
flats %>%
  filter(Кімнат == 2) %>%
  filter(Місто != "Києво-Святошинський") %>%
  summarise(mean(Загальна_площа), sd(Загальна_площа))
```

```
  mean(Загальна_площа) sd(Загальна_площа)
1             60.81832           16.61458
```

Можна задати назви стовпців, наприклад mean=mean(Загальна_площа):

```
flats %>%
  filter(Кімнат == 1) %>%
  filter(Місто != "Києво-Святошинський") %>%
  group_by(Місто) %>%
  summarise(mean=median(Загальна_площа), sd=sd(Загальна_площа))
```

```
# A tibble: 12 × 3
              Місто  mean        sd
              <chr> <dbl>     <dbl>
1           Вінниця  40.0  7.665871
2   Дніпропетровськ  32.0       NaN
3         Запоріжжя  36.4  9.050967
4  Івано-Франківськ  40.7  4.989404
5              Київ  39.0  8.015938
6             Львів  43.0  6.269465
7          Миколаїв  37.5  6.363961
8             Одеса  39.0  5.015531
9             Рівне  35.0 13.086362
10        Тернопіль  43.0  8.079379
11           Харків  18.5 10.472185
12     Хмельницький  42.0  6.669957
```

ВПРАВИ (4-8)

- Скільки змінних у наборі даних flats?
- Яка кількість міст у наборі даних flats?
- Чи всі з них дійсно є містами?
- Яка кількість трикімнатних квартир продається в Одесі?
- Яка медіана площ однокімнатних квартир у Львові?

Візуалізація даних

Для візуалізації даних будемо використовувати бібліотеку **ggplot2**. В процесі розвідувального аналізу даних (Exploratory Data Analysis) процеси очищення та візуалізації даних є циклічними. Для побудови графіків

використовується функція **ggplot()** Після виконання коду ви побачите графік у вкладці Plots у нижній правій панелі в RStudio.

• Першим аргументом цієї функції є набір даних (dataset).

• Далі ми вказуємо змінні з набору даних як параметр **aes**thetic, які будуть відображатись, наприклад, по осях x та y.

• Наступним кроком ми додаємо ще один рівень (об'єднавши їх знаком **+**) щоб задати **geom**etric об’єкт. Наприклад, для графіка розсіювання це **geom_point**, для лінійного графіка **geom_line**, для стовпчикової діаграми **geom_bar**.

СТОВПЧИКОВА ДІАГРАМА

Побудуємо стовпчикову діаграму для кількості кімнат:

```
ggplot(flats, aes(x=Кімнат)) +
  geom_bar(fill="lightblue",
           col="grey") +
  ylab('Кількість')
```

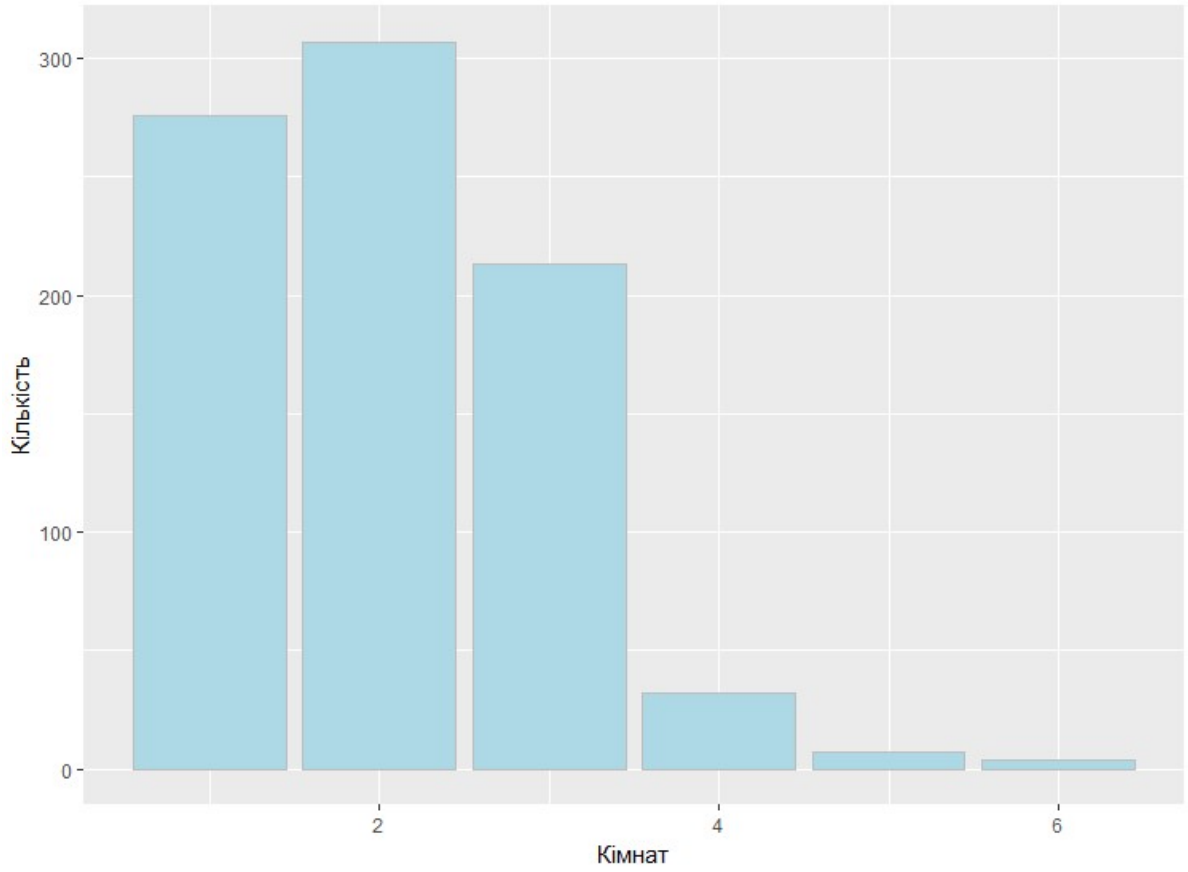

Побудуємо стовпчикову діаграму для змінної загальна площа:

```
p <- ggplot(flats, aes(x=Загальна_площа)) +
  geom_bar(fill="lightblue",
           col="grey") +
  ylab('Кількість')
p
```

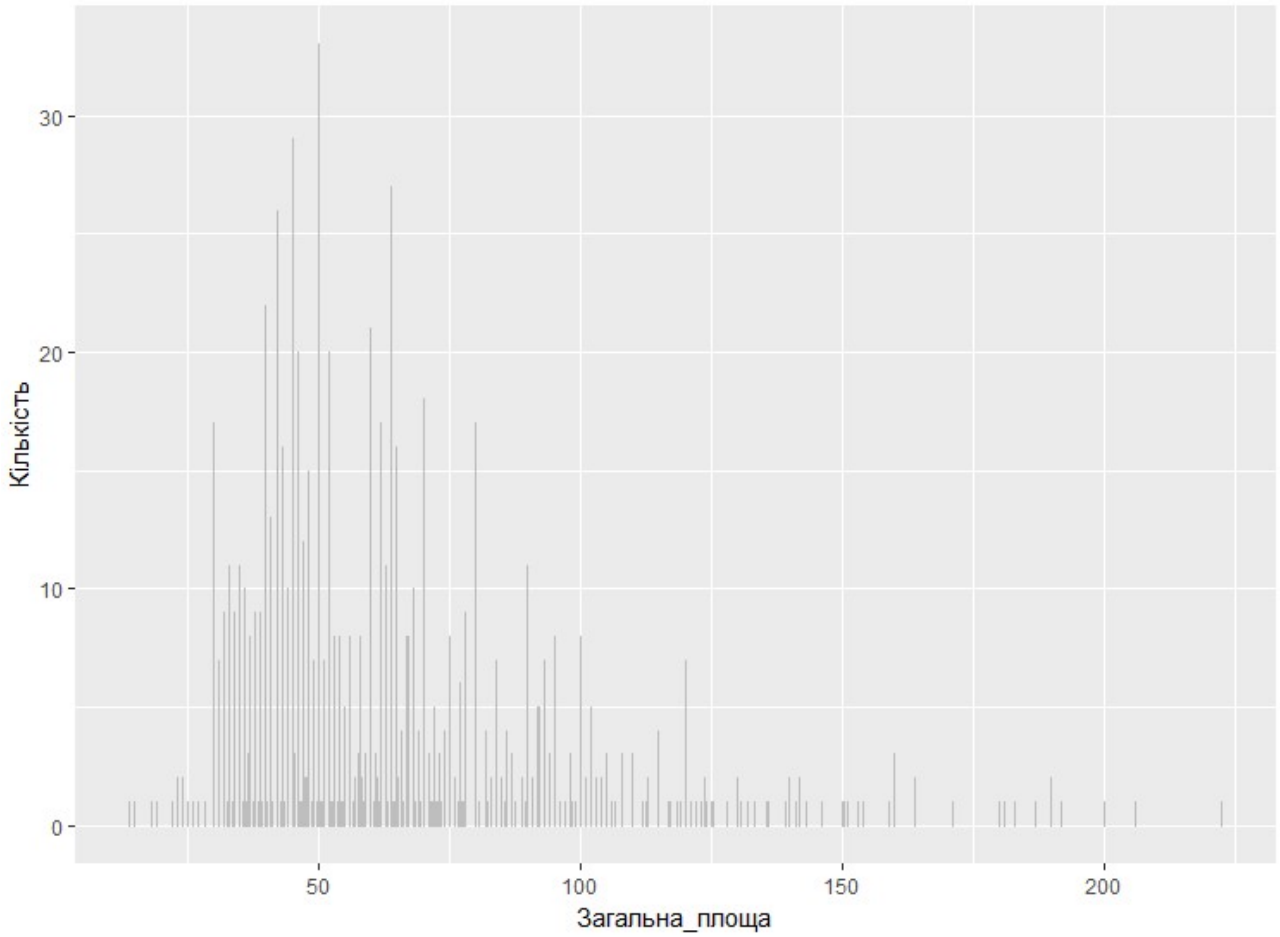

ГІСТОГРАМА

Використовується для оцінки форми розподілу кількісної змінної. На цьому графіку розподіл квартир, які продаються за загальною площею.

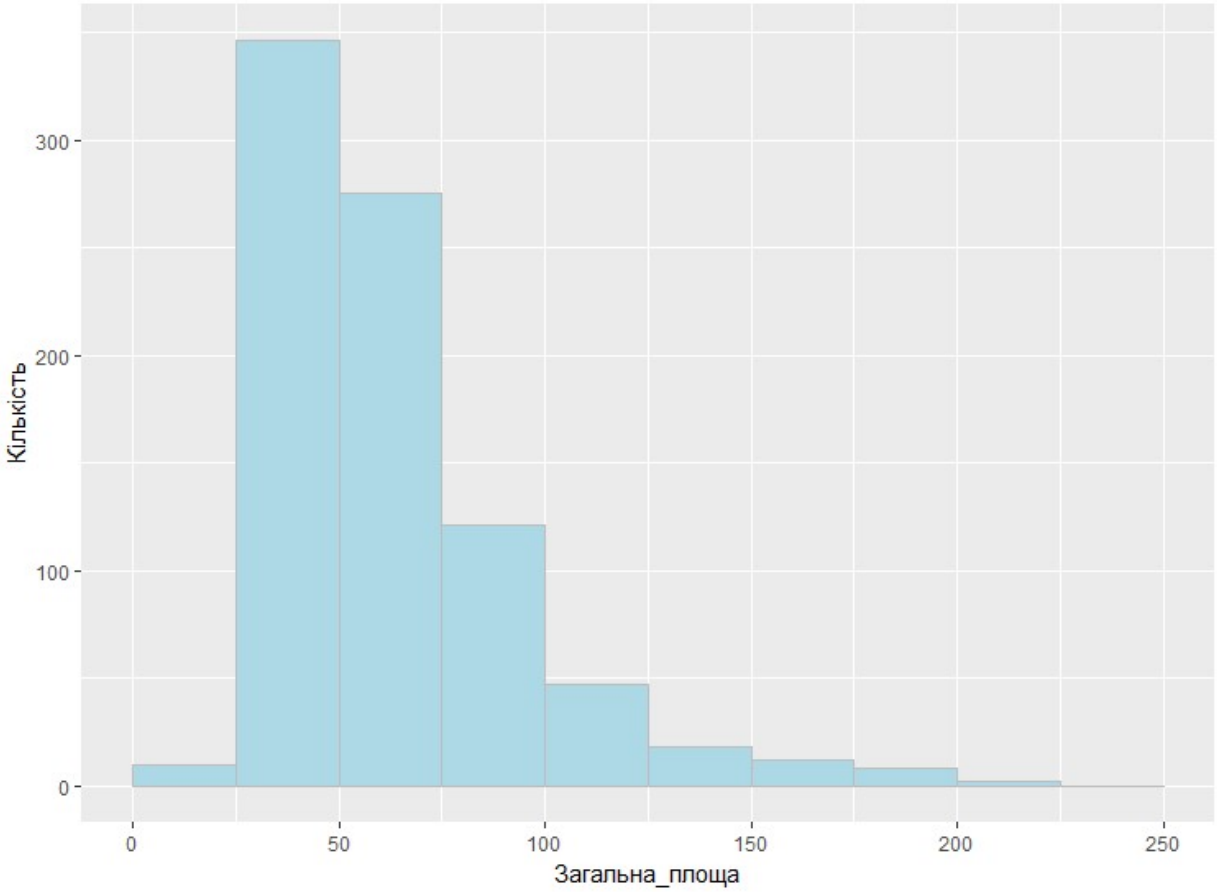

Залежно від розміру інтервалу її форма може змінюватися. Наприклад змінимо інтервал з 25 метрів квадратних до 50:

```
ggplot(flats, aes(x=Загальна_площа)) +
  geom_histogram(breaks=seq(0, 250, by = 50),
                 fill="lightblue",
                 col="grey") +
  ylab('Кількість')
```

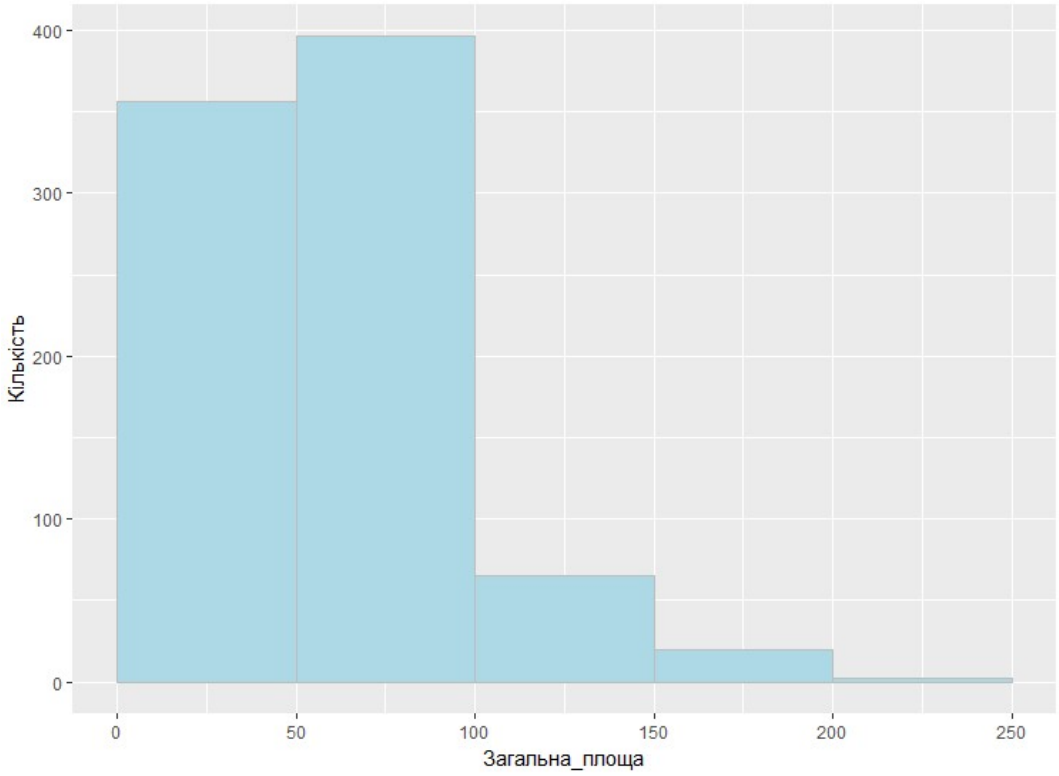

ГРАФІК РОЗСІЮВАННЯ

Побудуємо графік залежності ціни від загальної площі.

```
ggplot(flats, aes(x=Загальна_площа, y=Ціна)) +
  geom_point()
```

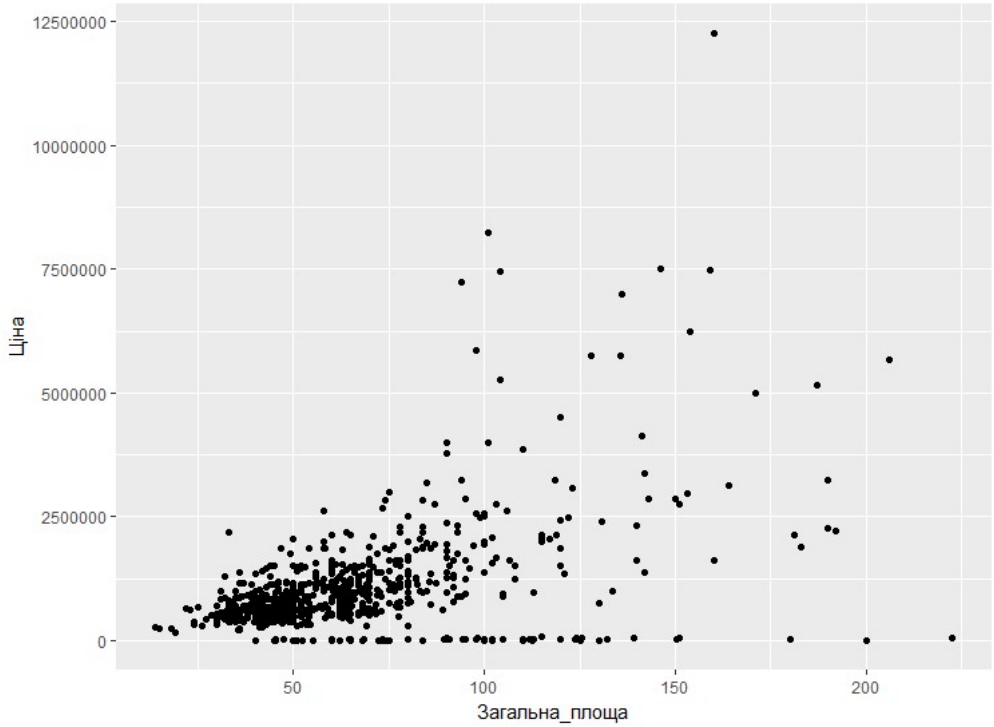

КОРОБЧАТА ДІАГРАМА

Порівняємо розподіл цін по містах та використаємо параметр **coord_flip()**, щоб розмістити коробчаті діаграми горизонтально:

```
ggplot(flats, aes(x=Місто, y=Ціна)) +
  geom_boxplot() +
  coord_flip()
```

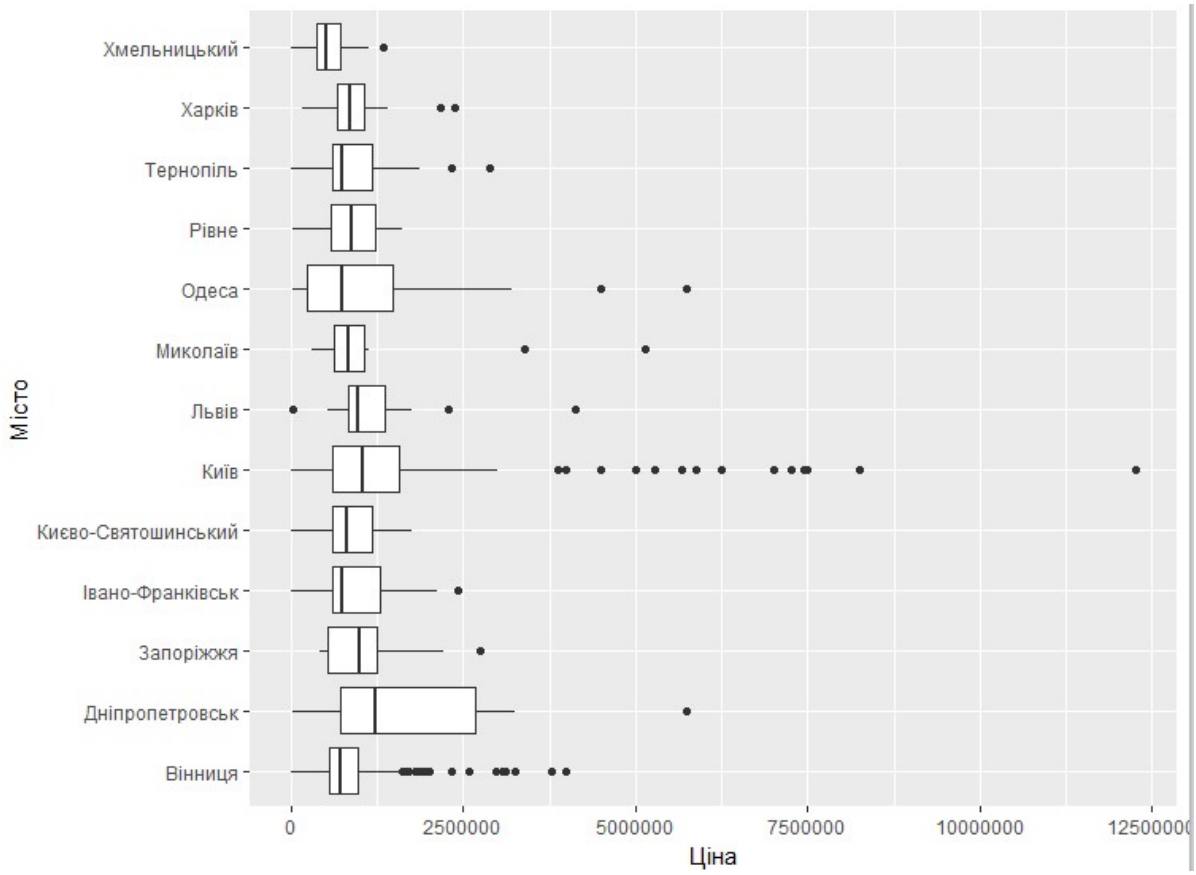

ВПРАВИ (9-11)

• Побудуйте коробчату діаграму для візулізації розподілу цін в залежності від кількості кімнат.

• Побудуйте графік розсіювання, який відображатиме залежність ціни від загальної площі.

• Побудуйте гістограму для оцінки розподілу ціни квартир.

Завдання:

Опрацювати теоретичний матеріал та виконати **вправи 1-11** (зберегти R Скрипт).